

1. 프로젝트 진행 동기

최근 텍스트 프롬프트를 통해 처음 보는 객체(Novel class)도 분할해내는 Open-vocabulary Segmentation 기술이 주목받고 있습니다. 본 프로젝트의 초기 단계에서는 객체 탐지(Grounding DINO)와 마스크 생성(SAM)을 순차적으로 이어 붙인 Two-stage 파이프라인을 구성하여 테스트를 진행했습니다. 하지만 이 방식은 이미지를 두 개의 무거운 모델에 각각 통과시켜야 하므로 연산량이 낭비되고 추론 속도가 현저히 느려지는 단점이 있었습니다. 이를 극복하고자, 단일 동결 백본(Single Frozen Backbone)만으로 마스크 생성과 분류를 동시에 수행하는 FC-CLIP (2023) 논문의 아키텍처를 분석하고 이를 파이프라인으로 구현해 보고자 하였습니다.


2. 논문에서 도출한 핵심 아이디어 (구현 목표)

FC-CLIP 논문을 분석하여 본 프로젝트에서 구현하고자 한 핵심 아이디어는 다음 세 가지입니다.

1. **Frozen Convolutional CLIP:** ViT 대신 고해상도 처리에 유리한 ConvNeXt 기반의 CLIP 을 사용하며, 기존의 Image-Text 지식이 훼손되지 않도록 가중치를 동결(Frozen)하여 사용한다.
2. **Mask Pooling:** 예측된 마스크 영역의 픽셀 피쳐만을 추출하여 객체의 특성을 나타내는 벡터를 생성한다.
3. **Geometric Ensemble (이중 분류기):** 학습 데이터에 최적화된 In-vocabulary 투영과 CLIP 의 원본 능력을 사용하는 Out-of-vocabulary 투영의 확률값을 기하학적 평균 수식으로 결합한다.

3. 파이프라인 설계 및 시행착오(초기 접근 방식의 실패 및 전략 수정)

처음에는 MaskPredictor 와 PixelDecoder 레이어를 PyTorch 의 nn.Module 로 직접 설계(From Scratch)하여 논문을 재현하려 시도했습니다. 하지만 직접 설계한 디코더는 랜덤 초기화(Random Initialization) 상태이므로, 이를 유의미하게 작동시키려면 COCO 데이터셋과 수십 대의 최고급 GPU 를 활용한 장기간의 사전 학습(Pre-training)이 필수적이라는 사실을 깨달았습니다. 학부 팀 프로젝트의 현실적인 환경(시간 및 단일 GPU 자원)에서는 불가능하다고 판단하여, 전략을 전면 수정했습니다. 이미 검증된 오픈소스 API(Hugging Face, GitHub)의 모듈들을 부품으로 활용하고, 이들을 논문의 아이디어(마스크 풀링 및 앙상블 수식)로 직접 결합하는 시스템 통합(System Integration) 방식을 채택했습니다.



원래 FC-CLIP 논문의 아키텍처는 보시다시피 하나의 CNN-based CLIP 에서 모든 것이 뻗어 나가는 구조입니다. 하지만 저희는 사전 학습의 현실적인 한계 때문에, 이 다이어그램의 위쪽 흐름(Pixel/Mask Decoder)은 Hugging Face 의 Mask2Former API 로 대체하고, 아래쪽 흐름(CNN-based CLIP 피쳐 추출)은 OpenCLIP 으로 대체하여 두 모델을 결합했습니다.

비록 백본을 완벽히 하나로 통합하진 못했지만, 그 이후에 이어지는 논문의 핵심인 Mask Pooling 과 Geometric Ensemble 수식은 저희가 직접 PyTorch 로 구현하여 파이프라인을 완성했습니다.

4. 구현된 논문의 아이디어 로직 (Code Workflow)

오픈소스를 결합하여 논문의 아이디어를 실제로 구현한 단계는 다음과 같습니다.

1. Mask Generation: Hugging Face 의 사전 학습된 Mask2Former 를 호출하여 이미지 내 객체들의 Class-Agnostic 마스크 위치(100 개)만 추출합니다.

2. Feature Extraction: GitHub 의 open_clip (ConvNeXt-Large)에 이미지를 통과시켜 풍부한 공간 정보가 담긴 1536 차원의 Multi-scale 피쳐맵을 추출합니다.

3. Mask Pooling & Ensemble 구현: 추출된 피쳐맵과 마스크 위치를 기반으로 텐서 행렬곱(einsum)을 이용해 논문의 Mask Pooling 을 직접 구현했습니다. 이후 두 개의 투영 브랜치(In-vocab, Out-vocab)를 거친 뒤, 논문의 7 번 수식인 ****기하학적 앙상블($p_{in}^{1-\beta} \times p_{out}^{\beta}$)****을 적용하여 최종 세그멘테이션 스코어를 도출했습니다.

5. 미완성 사항 및 한계점 (Limitations)

오픈소스를 성공적으로 결합하여 추론(Forward) 파이프라인을 구축했으나, 다음과 같은 한계점이 남았습니다.

- 1. End-to-End 파인튜닝의 부재:** Mask2Former 모듈과 CLIP 백본을 하나로 묶어 오차를 역전파(Backpropagation)하는 End-to-End 학습을 진행하지 못했습니다. 두 모델이 독립적으로 작동한 결과를 수학적으로 결합한 상태이므로, 객체의 경계선이나 미세한 인식 정확도는 논문의 SOTA 성능에 미치지 못합니다.

2. **Out-of-vocab 투영층의 미학습:** 논문에서는 CLIP 의 원본 프로젝션 헤드를 재사용할 것을 권장하나, 사용한 오픈소스 라이브러리 간의 출력 차원(1536 차원)과 텍스트 임베딩 차원(768 차원)의 불일치로 인해 임의의 nn.Linear(1536, 768) 레이어를 삽입하여 차원을 맞추는 타협을 했습니다. 해당 레이어가 미학습 상태이므로 일부 결과에 노이즈가 발생할 수 있습니다.

6. 결론

본 프로젝트는 단순히 SOTA 모델의 API 를 호출하는 것을 넘어, 최신 논문(FC-CLIP)이 제안하는 복잡한 수식과 구조적 아이디어를 분석하였습니다. 이를 바탕으로 분산된 오픈소스 모델들을 엔지니어링하여 하나의 Single-stage 파이프라인으로 직접 통합(Integration)해 내는 귀중한 실무적 경험을 얻을 수 있었습니다.

7. 참고문헌 (References)

- [1] Yu, Q., et al. (2023). Convolutions Die Hard: Open-Vocabulary Segmentation with Single Frozen Convolutional CLIP. *NeurIPS*.
- [2] Kirillov, A., et al. (2019). Panoptic Segmentation. *CVPR*.
- [3] Hugging Face. (2022). Mask2Former Model Documentation.
- [4] Ilharco, G., et al. (2021). OpenCLIP. *Zenodo*.